

Cuánto cuesta una consulta

Dos agentes —el que busca en ecommerce foráneas y el que evalúa aditivos contra el eCFR— multiplican la factura hasta 32×. Aquí está de dónde sale cada centavo, medido contra el código y la auditoría — no estimado.

Tarifas GLM \$1,40 / \$4,40 · DeepSeek v4 flash \$0,14 / \$0,28 por millón

Fuente payload interceptado + etapas_ejecucion Fecha 24 ago 2026

01 Resumen

Una consulta sin agentes cuesta entre **\$0,0084 y \$0,0180**: dos llamadas al modelo y nada más. Hay **dos agentes** que pueden entrar encima — el comercial, que busca en ecommerce foráneas, y el del eCFR, que evalúa aditivos. Juntos y con caché fría llevan la consulta hasta **\$0,270**.

SIN AGENTES

\$0,0084–0,0180

Etapa 1 en DeepSeek + etapa 3 en GLM. El resto del DAG gratuito no consume tokens.

+ AGENTE COMERCIAL

\$0,0342–0,1034

Góndolas alemana y suiza, más la cuarentena si el producto no está indexado.

+ 6 ADITIVOS (ECFR)


\$0,0824–0,2701

Los aditivos solos son el 57–62 % de la factura con caché fría. Se precalientan por \$27,80.

Costo de una consulta, por estado del catálogo y comportamiento de la web

Dólares por consulta. El DAG se paga siempre; los dos agentes solo cuando entran.

- DAG (etapas 1 y 3)
- Agente comercial (góndolas + cuarentena)
- Aditivos · agente eCFR (6, caché fría)



La respuesta, en una tabla

COSTO POR CONSULTA · DÓLARES				
ESTADO DEL CATÁLOGO	SIN AGENTE	CON AGENTE	LO QUE SUMA	FACTOR
Catálogo pleno (30 productos)	\$0,01798	—	—	—
↳ escenario medio ● MEDIO	\$0,01798	\$0,03515	\$0,01717	2,0×
↳ escenario caótico ● CAÓTICO	\$0,01798	\$0,08130	\$0,06332	4,5×
No indexado (0 productos)	\$0,00844	—	—	—
↳ escenario medio ● MEDIO	\$0,00844	\$0,03419	\$0,02575	4,1×
↳ escenario caótico ● CAÓTICO	\$0,00844	\$0,10341	\$0,09497	12,3×
+ análisis de 6 aditivos (caché fría)	—	—	—	—
↳ sobre el caso medio ● MEDIO	\$0,03515	\$0,08241	\$0,04726	2,3×
↳ sobre el caso caótico ● CAÓTICO	\$0,10341	\$0,27013	\$0,16672	2,6×

El análisis de aditivos no corre en cada consulta: es un endpoint aparte que se dispara al abrir un producto del informe. Por eso va como capa encima y no dentro de las filas anteriores.

Lo que significa al mes

PROYECCIÓN MENSUAL · DÓLARES			
CONSULTAS / MES	SIN AGENTE	AGENTE MEDIO	AGENTE CAÓTICO
1.000	\$17,98	\$35,15	\$103,41
5.000	\$89,91	\$175,75	\$517,05
10.000	\$179,83	\$351,50	\$1.034,10

«Sin agente» hoy no es una opción del usuario

El selector de fuentes todavía no filtra: toda consulta lanza las góndolas alemana y suiza marque quien consulta lo que marque. Los únicos frenos son `AGROSCOUT_GONDOLA_DE=0` y `AGROSCOUT_GONDOLA_CH=0`, que son variables de despliegue, no una decisión de quien pregunta.

02 El agente

El agente gasta tokens en un solo sitio: `_pedir_extraccion`. La búsqueda de Tavily, la lectura de JSON-LD y el *grounding check* son deterministas y no cuestan un token. Todo el costo del agente es «leer una página que no publica sus datos en limpio».

La entrada, medida byte a byte

Interceptando el payload antes de que salga a la red, con la página al tope de `MAX_CARACTERES_HTML = 6000`:

UNA EXTRACCIÓN · TOKENS DE ENTRADA			
COMPONENTE	TOKENS	PESO	NOTA
System prompt del extractor	328	10 %	Fijo. Se paga entero en cada página.
Schema de <code>ProductoSchema</code>	583	18 %	Lo manda instructor como definición de herramienta.
Texto de la página	2.385	72 %	6.024 caracteres alemanes → 2,53 car/token.
Entrada por extracción	3.296	100 %	911 de ellos son sobrecarga fija.

El alemán es caro de tokenizar: 2,53 caracteres por token frente a los ~3,3 del castellano. La misma página en español costaría un 25 % menos.

La salida: el modelo razona antes de responder

El JSON útil son 65 tokens. Pero glm-5.2 piensa antes de contestar, y eso se cobra como salida. La cifra se deriva de las latencias ya medidas contra fichas reales — 15,4 s y 41,8 s — a los ~24 tokens/s que genera el modelo.

COSTO DE UNA EXTRACCIÓN				
CASO	SALIDA	GLM	DEEPSEEK	FACTOR
Página rápida (15,4 s)	370 tok	\$0,006242	\$0,000565	11,0×
Página lenta (41,8 s)	1.000 tok	\$0,009014	\$0,000741	12,2×

Anatomía de una pasada

Una pasada = una búsqueda en Tavily (`max_results=5`) → hasta **3 URLs**. Cada URL intenta primero el JSON-LD, que es exacto, instantáneo y gratis; solo las que no lo traen pagan modelo. La tasa medida es de **5 de 8 fichas peruanas (62,5 %)** — y no hay medición equivalente para Alemania o Suiza.

QUÉ SEPARA EL ESCENARIO MEDIO DEL CAÓTICO		
PARÁMETRO	MEDIO	CAÓTICO
Fichas con JSON-LD	62,5 % (medido en Perú)	0 % — las 3 URLs pagan
Extracciones por pasada	1,12	3,00
Salida por extracción	685 tok	1.000 tok
Reintentos	ninguno	1 — reenvía la entrada entera

UNA PASADA DE AGENTE • UN MERCADO						
ESCENARIO	EXTRACCIONES	ENTRADA	SALIDA	GLM	DEEPSEEK	FACTOR
● MEDIO	1,12	3.708	771	\$0,00858	\$0,00073	11,7×
● CAÓTICO	3,00	13.184	3.000	\$0,03166	\$0,00269	11,8×

En el caso caótico, el 89 % del gasto es entrada

Los 911 tokens fijos se pagan enteros en cada una de las cuatro llamadas, y el reintento reenvía los 3.296 completos. Recortar el schema o el system prompt vale más que recortar la página.

Las constantes que fijan el techo

TOPES DEL AGENTE, TAL COMO ESTÁN EN EL CÓDIGO		
CONSTANTE	VALOR	QUÉ ACOTA
<code>MAX_CARACTERES_HTML</code>	6.000	Cuánta página ve el modelo. Es el 72 % de la entrada.
URLs por pasada	3	Tope duro del bucle de <code>ejecutar()</code> .
<code>MAX_OFERTAS_POR_PAGINA</code>	5	Ofertas que salen de una página de categoría. No afecta al costo.
<code>_REINTENTOS</code>	3	Cada reintento reenvía la entrada completa.
Tope común de góndolas	90 s	Reloj de pared compartido por Alemania y Suiza.
Tope de la cascada N3	120 s	<code>asyncio.wait_for</code> alrededor de la pasada de cuarentena.

03 El DAG

De las seis etapas del DAG, solo dos llaman al modelo. Estos tokens no son una estimación: están registrados en `etapas_ejecucion` por corridas reales.

Etapa por etapa

EL DAG CON CATÁLOGO PLENO • TOKENS MEDIDOS				
ETAPA	MODELO	ENTRADA	SALIDA	COSTO
1 • Interpretar insumo	deepseek-v4-flash	606	548	\$0,000238
2a • Buscar productos	vectores, sin LLM	0	0	\$0
2b • Mapa comercial	sync, sin LLM	0	0	\$0
3 • Insight de mercado	glm-5.2	6.377	2.004	\$0,017745
Consulta gratuita		6.983	2.552	\$0,017983

La etapa 2b no consume tokens propios, pero es desde donde se lanzan las góndolas por agente. Ese gasto no aparece en esta tabla — ni en la auditoría.

La etapa 3 escala con el catálogo

Cruzando `entrada_json` con los tokens registrados en cinco corridas reales, la relación es directa: cada producto que devuelve el catálogo añade unos **176 tokens** al prompt de insight.

ETAPA 3 SEGÚN PROFUNDIDAD DEL CATÁLOGO				
PRODUCTOS	ENTRADA	SALIDA	COSTO	ESTADO
0	1.100	1.514	\$0,00820	No indexado
3	1.315	1.380	\$0,00791	Indexado parcial
30	6.377	2.004	\$0,01775	Indexado pleno

La salida se mantiene casi constante entre 1.400 y 2.000 tokens: el modelo escribe un insight de longitud parecida tenga treinta productos o ninguno. Lo que se dispara es la entrada.

El hueco: las etapas premium

Las etapas 4 y 5 nunca corrieron con auditoría de tokens

Cero filas en `etapas_ejecucion`. De ellas solo se conoce el prompt fijo — 557 y 827 tokens — medido interceptando el payload. La parte variable de la etapa 5 es el contexto RAG del corpus regulatorio, que puede ser grande y no está acotada por ninguna constante equivalente a `MAX_CARACTERES_HTML`. Toda la proyección de este informe cubre la ruta gratuita; una consulta premium sigue sin cifra.

LO QUE SE SABE DE LAS ETAPAS PREMIUM			
ETAPA	MODELO	PROMPT FIJO	PARTE VARIABLE
4 · Formular hipótesis	glm-5.2	557 tok	Los productos del catálogo, igual que la etapa 3.
5 · Verificar regulación	glm-5.2	827 tok	Contexto RAG del corpus regulatorio. Sin acotar.
6 · Informe scout	PDF, sin LLM	0	—

04

Aditivos

El análisis de aditivos es la **parte más cara del sistema** — más que las góndolas y la etapa 3 juntas. Con seis aditivos y caché fría cuesta \$0,047 en el caso medio, cuando la consulta entera cuesta \$0,035.

Un segundo agente, con un modelo de costo distinto

No es el agente comercial. Es `AgenteECFR`, que lee secciones del *Code of Federal Regulations* para decidir si un aditivo está autorizado en EE. UU. Lee el doble de texto por llamada (`MAX_CARACTERES = 12000`) y puede hacer hasta tres llamadas por aditivo.

Tres mercados, un solo costo

El orquestador evalúa cada aditivo en tres mercados a la vez. Solo uno gasta dinero:

LOS TRES EVALUADORES			
MERCADO	MECANISMO	LATENCIA	COSTO
EE. UU.	Agente en vivo contra el eCFR	15–36 s	● PAGA
Unión Europea	Anexo II en local	< 8 ms	● \$0
Codex	Tabla curada a mano	< 1 ms	● \$0

La UE y el Codex son diccionarios en memoria: cachearlos añadiría una capa de invalidación para ahorrar microsegundos. Toda la factura de esta pestaña es la columna de EE. UU.

Una lectura de sección, medida

Mismo método que con el agente comercial — payload interceptado antes de la red, con la sección al tope de `MAX_CARACTERES = 12000` :

UNA LECTURA DEL ECFR • TOKENS DE ENTRADA		
COMPONENTE	TOKENS	NOTA
System prompt	505	Más largo que el comercial: define qué es leer y qué es decidir.
Schema de <code>LecturaSeccion</code>	538	Lo manda instructor en cada llamada.
Sección del CFR	2.430	12.094 caracteres → 4,98 car/token.
Entrada por lectura	3.473	Similar al comercial pese a leer el doble de texto.

El inglés jurídico es barato de tokenizar

4,98 caracteres por token, frente a los 2,53 del alemán de las fichas de tienda. Por eso 12.000 caracteres de CFR caben en 2.430 tokens y 6.000 de tienda alemana necesitan 2.385: el doble de texto por casi el mismo precio.

COSTO DE UNA LECTURA				
CASO	SALIDA	GLM	DEEPSEEK	FACTOR
Rápida (~15 s)	370 tok	\$0,00649	\$0,00059	11,0×
Media (~28 s)	685 tok	\$0,00788	\$0,00068	11,6×
Lenta (~36 s)	1.000 tok	\$0,00926	\$0,00077	12,1×

De una lectura a seis aditivos

El bucle prueba hasta `MAX_CANDIDATAS = 3` secciones y **corta en la primera que da un veredicto con `grounding`**. Ese corte temprano es el eje medio/caótico de esta pestaña: una candidata acertada, o tres que no cubren el aditivo.

UN ADITIVO					
ESCENARIO	LECTURAS	ENTRADA	SALIDA	GLM	DEEPSEEK
MEDIO	1	3.473	685	\$0,00788	\$0,00068
CAÓTICO	3	10.419	3.000	\$0,02779	\$0,00230

LA CONSULTA DE 6 ADITIVOS · CACHÉ FRÍA				
ESCENARIO	LECTURAS	GLM	DEEPSEEK	FACTOR
MEDIO	6	\$0,04726	\$0,00407	11,6×
CAÓTICO	18	\$0,16672	\$0,01379	12,1×

Los seis van en paralelo con `asyncio.gather`, así que el producto entero tarda lo que su aditivo más lento —unos 36 s— en vez de la suma. Eso arregla la latencia, no el costo: se pagan los seis igual.

En contexto: lo que pesa de verdad

LA CONSULTA CON Y SIN LA PESTAÑA DE ADITIVOS				
ESCENARIO	SIN ADITIVOS	CON 6 ADITIVOS	FACTOR	PESO DE LOS ADITIVOS
Medio · GLM	\$0,03515	\$0,08241	2,3×	57 %
Caótico · GLM	\$0,10341	\$0,27013	2,6×	62 %
Medio · agentes en DeepSeek	\$0,03515	\$0,03922	1,1×	10 %
Caótico · agentes en DeepSeek	\$0,10341	\$0,11720	1,1×	12 %

Con GLM, los seis aditivos son **más de la mitad de la factura**. Movidos a DeepSeek pasan a ser el 10 %: es el mismo cambio de modelo que ya se propone para el agente comercial, y aquí rinde todavía más.

La caché lo cambia todo

La clave es (aditivo, matriz), no el producto, y el TTL es de 90 días. Dos productos distintos con sorbato de potasio en pulpa de fruta comparten respuesta. Eso convierte el costo en una inversión acotada, no en un gasto por consulta.

CALENTAR LA CACHÉ ENTERA • 36 ADITIVOS DISTINTOS			
ALCANCE	PARES	GLM	DEEPSEEK
5 matrices del piloto	180	\$1,42	\$0,12
20 matrices realistas	720	\$5,67	\$0,49
Las 98 matrices del Anexo II	3.528	\$27,80	\$2,40

Precalentar es la jugada obvia

El universo entero —36 aditivos × 98 matrices— cabe en **\$27,80 una vez cada 90 días**. Hecho eso, el análisis de aditivos pasa a costar cero en producción y responde en milisegundos. Hoy en cambio lo paga, de uno en uno y a plena tarifa, el primer usuario que pregunte por cada combinación.

La fuga: SIN_DATO no se cachea

Un aditivo que falla siempre, se paga siempre

La decisión de no cachear SIN_DATO es correcta en su intención: suele venir de un fallo de red y no conviene congelar un error durante 90 días. Pero el efecto secundario es que **un aditivo cuya búsqueda no devuelve nada en el corpus local nunca deja de pagarse** — cada consulta reintenta las tres candidatas y vuelve a cobrar \$0,028. La distinción que falta es entre «no se pudo comprobar» (transitorio, no cachear) y «el corpus no tiene esta sección» (estable, cachear con un TTL corto).

05 Escenarios

Dos ejes gobiernan el costo: si el producto está en el catálogo, y si las tiendas foráneas publican sus fichas en limpio. Solo uno de los dos mueve la factura de verdad.

Qué decide cada eje

La puerta que dispara la tercera pasada

`_has_gaps` escala a N3 si hay 0 productos, menos de 3, menos de 2 países o menos de 2 marcas. **Pero las góndolas alemana y suiza no pasan por esa puerta:** se lanzan desde la etapa 2b sin comprobar nada. El suelo son siempre dos pasadas de agente; el catálogo solo decide si hay una tercera.

La matriz completa

CON LA EXTRACCIÓN EN GLM · COMO ESTÁ HOY						
CATÁLOGO	PASADAS	ESCENARIO	ETAPA 1	ETAPA 3	AGENTE	TOTAL
No indexado (0)	3	MEDIO	\$0,00024	\$0,00820	\$0,02575	\$0,03419
No indexado (0)	3	CAÓTICO	\$0,00024	\$0,00820	\$0,09497	\$0,10341
Parcial (3)	3	MEDIO	\$0,00024	\$0,00791	\$0,02575	\$0,03390
Parcial (3)	3	CAÓTICO	\$0,00024	\$0,00791	\$0,09497	\$0,10312
Pleno (30)	2	MEDIO	\$0,00024	\$0,01775	\$0,01716	\$0,03515
Pleno (30)	2	CAÓTICO	\$0,00024	\$0,01775	\$0,06332	\$0,08130

CON LA EXTRACCIÓN EN DEEPSEEK V4 FLASH · PROPUESTA						
CATÁLOGO	PASADAS	ESCENARIO	ETAPA 1	ETAPA 3	AGENTE	TOTAL
No indexado (0)	3	MEDIO	\$0,00024	\$0,00820	\$0,00220	\$0,01064
No indexado (0)	3	CAÓTICO	\$0,00024	\$0,00820	\$0,00806	\$0,01650
Parcial (3)	3	MEDIO	\$0,00024	\$0,00791	\$0,00220	\$0,01036
Parcial (3)	3	CAÓTICO	\$0,00024	\$0,00791	\$0,00806	\$0,01621
Pleno (30)	2	MEDIO	\$0,00024	\$0,01775	\$0,00147	\$0,01945
Pleno (30)	2	CAÓTICO	\$0,00024	\$0,01775	\$0,00537	\$0,02336

El eje del catálogo casi se cancela solo

Un 3 % de diferencia donde se esperaba el doble

No indexado en escenario medio cuesta \$0,03419; indexado pleno, \$0,03515. Lo que se ahorra en la etapa 3 por no tener productos que describir se gasta en la tercera pasada de agente que dispara `_has_gaps`. **El catálogo no ahorra dinero: cambia dónde se gasta.** Lo que sí manda es el escenario — de medio a caótico la pasada se multiplica por 3,7× y la consulta entera por 2,9×.

Mejor y peor caso al mes

PROYECCIÓN MENSUAL · DÓLARES			
CONSULTAS / MES	MEJOR PLENO · MEDIO	PEOR NO IDX · CAÓTICO	PEOR EN DEEPSEEK
500	\$17,57	\$51,71	\$8,25
1.000	\$35,15	\$103,41	\$16,50
5.000	\$175,74	\$517,06	\$82,49
10.000	\$351,48	\$1.034,13	\$164,97

El peor caso en DeepSeek cuesta menos que la mitad del mejor caso en GLM. Movida la extracción, el agente deja de ser la decisión cara.

06 Hallazgos

Medir el costo obligó a leer el camino del dinero entero. Aparecieron siete cosas que mueven la cifra y que no son de modelo, sino de código.

01 Las tarifas de la app están mal, y por mucho ● CRÍTICO

`config/tarifas_llm.json` tiene glm-5.2 a \$10 por millón de entrada y \$20 de salida: 7,1× y 4,5× por encima de las reales. Como `nivel_maximo_costo` es un invariante que degrada a «sin dato» al tope, el presupuesto se agota antes de tiempo.

`config/tarifas_llm.json`

02 El gasto del agente no llega a la auditoría ● CRÍTICO

Las góndolas viven dentro de la etapa 2b, que se registra con `etapa_sync` → `costo_usd=0.0, modelo="sync"`. Hasta el 92 % del costo de una consulta caótica es invisible para el cost-meter.

`casos_de_uso/etapas/ejecutor.py:141`

03 El selector de fuentes no filtra ● ALTO

Las cuatro fuentes se lanzan marque el usuario lo que marque. Toda consulta paga las dos góndolas por agente; los únicos frenos son variables de entorno de despliegue.

`api/main.py:169`

04 El timeout de góndola paga y tira ● ALTO

El ejecutor se cierra con `wait=False`: al vencer el tope de 90 s se descarta el resultado, pero las extracciones ya lanzadas siguen corriendo y se cobran igual.

`casos_de_uso/etapas/mapear_comercio.py`

05 La ruta de góndolas no tiene caché ● ALTO

Las etapas del DAG pasan por `etapa()`, que cachea. Las góndolas llaman al agente directamente: dos consultas idénticas del mismo insumo el mismo día pagan dos veces.

`adaptadores/catalogo_alemania.py · catalogo_suiza.py`

06 Un aditivo sin sección en el corpus se paga en cada consulta ● CRÍTICO

`SIN_DATO` no se cachea, y con razón: suele venir de un fallo de red y congelarlo 90 días sería peor. Pero eso deja fuera también el caso estable — el corpus local no tiene esa sección — que reintenta las tres candidatas y vuelve a cobrar \$0,028 cada vez que alguien pregunta. Falta separar «no se pudo comprobar» de «aquí no está».

`casos_de_uso/analizar_aditivos_mercados.py:379`

07 La caché de aditivos nunca se precalienta ● ALTO

El universo entero de aditivos entra en \$27,80 una vez cada 90 días. Hoy lo paga de uno en uno el primer usuario que pregunte por cada par `(aditivo, matriz)`, a plena tarifa y con 36 s de espera.

`casos_de_uso/analizar_aditivos_mercados.py:70`

Los dos primeros hallazgos se cancelan — pero solo en un punto

El cost-meter cobra \$0,10423 por consulta contando solo las etapas 1 y 3. Va 3× alto en la tarifa y se deja el agente entero fuera; las dos direcciones se compensan por casualidad justo en el caso caótico.

DÓNDE CORTA EL PRESUPUESTO FRENTE A LO QUE SE GASTÓ DE VERDAD			
PLAN	TOPE	CORTA A LAS	GASTO REAL AHÍ
Gratuito	\$2,00 / mes	19 consultas	\$0,67 – \$1,98
Premium	\$10,00 / mes	96 consultas	\$3,37 – \$9,92

Arreglar uno sin el otro rompe el invariante en el sentido contrario

Corregir la tarifa sin empezar a contabilizar el agente haría que el meter pasara a cortar tarde en vez de pronto. Los dos hallazgos son una sola corrección.

La recomendación

Mover los dos agentes de glm-5.2 a deepseek-v4-flash

La extracción es rellenar un schema con lo que está literalmente en el texto — no razonamiento — y aguas abajo ya hay un *grounding check* determinista que rechaza cualquier valor que no aparezca en el HTML de origen. Son 11× menos en esa ruta sin tocar el contrato ni añadir riesgo. Lo mismo vale, y rinde más, para `AgenteECFR.MODELO`: ahí el modelo también lee y el código decide, con grounding contra la norma. Movidos los dos, los seis aditivos pasan del 57 % de la factura al 10 %.

casos_de_uso/agente/agente.py:118 · adaptadores/agente_ecfr.py:83

Lo que falta medir

- **La tasa de JSON-LD en Alemania y Suiza.** El 62,5 % está medido sobre ocho fichas peruanas. Toda la diferencia entre el escenario medio y el caótico — el 2,9× de la factura — depende de ese número en tiendas foráneas, y ahí no hay ni una medición. Rapunzel, Alnatura, Migros, Coop y Piccantino son media hora: descargar sus fichas y contar cuántas traen `schema.org/Product`.
- **Una consulta premium real.** Las etapas 4 y 5 tienen cero filas con tokens. Basta ejecutar una y volver a leer la auditoría.
- **El costo de Tavily.** Cada pasada gasta una búsqueda; dos o tres por consulta. No es LLM y no entra en estas cifras, pero sí en la factura.

Todas las cifras de tokens salen de dos fuentes: el payload real interceptado antes de salir a la red (prompts fijos, schema de instructor, contenido de página) y la tabla `etapas_ejecucion` de `agroscout.db` (etapas 1 y 3, cinco corridas). Los tokens de salida del agente se derivan de latencias medidas contra fichas reales a ~24 tokens/s. Lo que es supuesto — la tasa de JSON-LD foránea, el número de reintentos del caso caótico — está declarado como tal en las pestañas de cada agente.